Розеттский камень

Пуассон, фея и три мексиканских негодяя

2019-09-16

Оглавление

Глава 1

Напутственное слово

Глава 2

Коан об установке софта

В этом коане мы рассмотрим установку и настройку программ для работы на языках программирования R и Python, а также установку и настройку программы Stata.

###Язык программирования R > R - это открытая среда программирования, помогающая в работе со статистическими данными. Для программирования на R подойдет программа RStudio.

Рассмотрим установку RStudio на Mac OS и Windows.

#####Инструкция по установке RStudio для Windows / Mac OS:

1. Загрузите и установите язык программирования R с официального сайта.

   - Версия для Windows: Выберите “Download R for Windows” ▸ “base” ▸ “Download R 3.x.x for Windows”.

   - Версия для Mac OS: Выберите “Download R for (Mac) OS X” ▸ “Latest Release” ▸ “R 3.x.x”.

2. Загрузите программу RStudio с официального сайта разработчика (выберите подходящую версию из предложенных опций). Возможностей бесплатной версии будет вполне достаточно для работы.

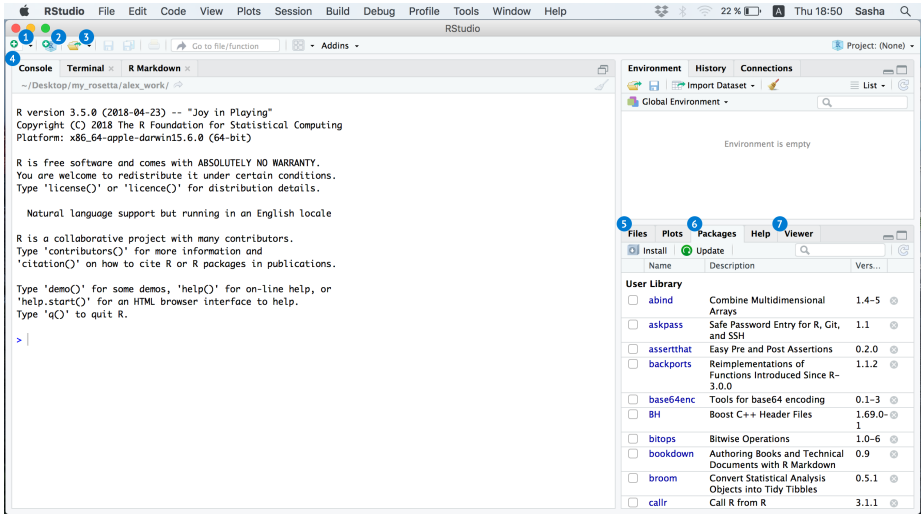

Рис. 2.1: *Интерфейс программы*

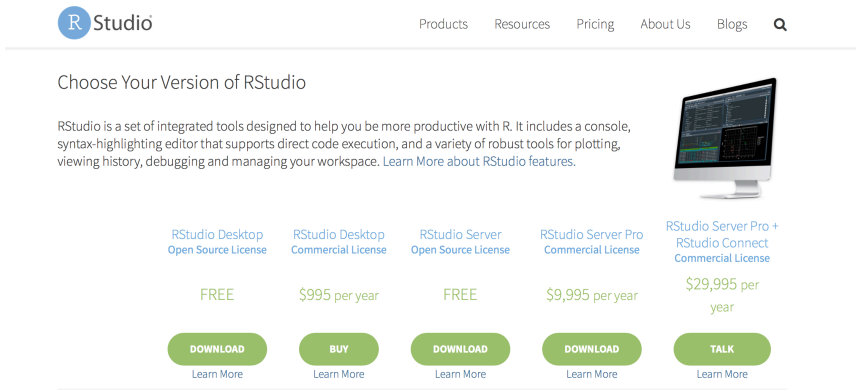

Готово, Вы можете использовать RStudio на вашем компьютере.

#####Начало работы

1. **New file** - Создание нового файла.
2. **New project** - Создание нового проекта.
3. **Open file** - Открытие существующего файла.
4. **Console** - Консоль, в которой набирается код.
5. **Files** - Список файлов, доступных для работы.
6. **Packages** - Список установленных пакетов, т.е. расширений. Также можно ознакомиться с ним, введя в консоль команду *installed.packages()*.

7. **Viewer** - Отображение введенного кода.

###Язык программирования Python > Python - это ещё одна открытая среда программирования, помогающая в работе со статистическими данными. Для программирования на Python подойдет программа Jupyter Notebook.

#####Установка

1. Загрузите и установите Anaconda с официального сайта.

2. После загрузки и установки откройте Anaconda Navigator, через который Вы сможете открыть программу Jupyter Notebook. Navigator.bb

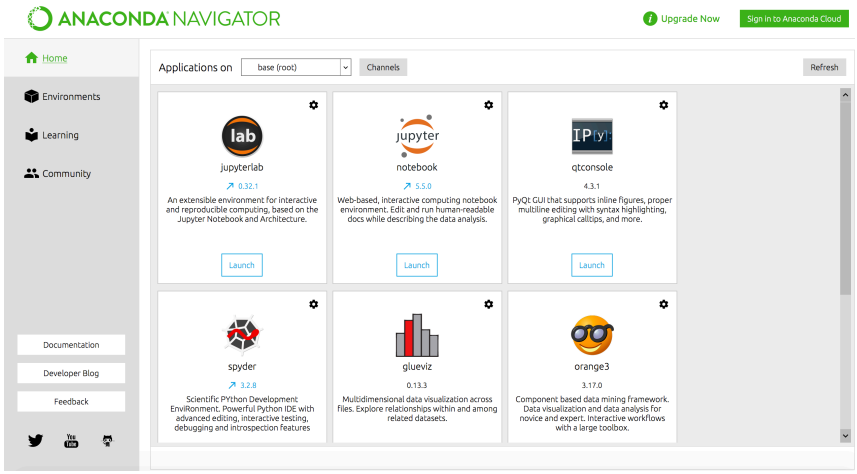

#####Начало работы

Открыв Jupyter Notebook, вы попадете на страницу, содержащую ваши сохраненные файлы. Чтобы создать новый файл, нажмите “New” ▸ “Notebook: Python

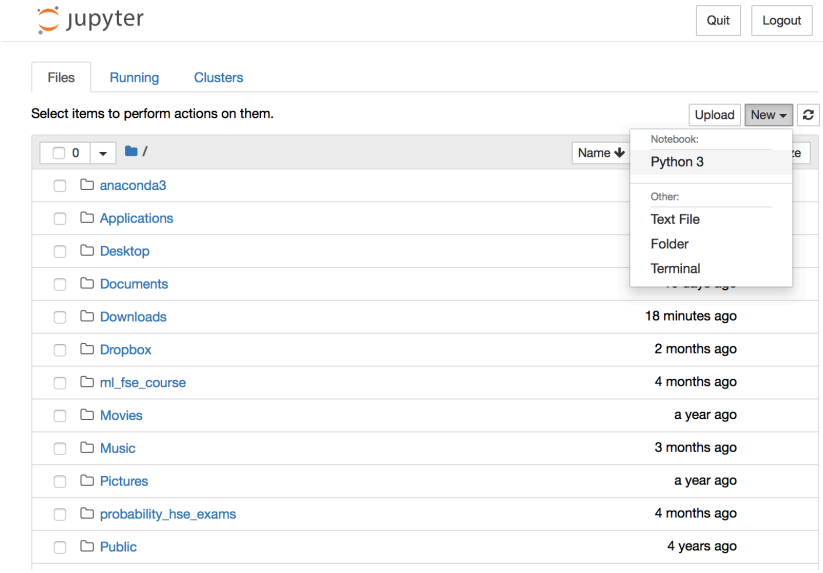

3". File in Jupyter.bb

Затем, в открывшемся окне, появится новый файл. Теперь все готово к работе. Вы можете вводить свой код и затем, используя комбинацию клавиш "Shift" + "Enter", проверять его исполнение. in Jupyter.bb

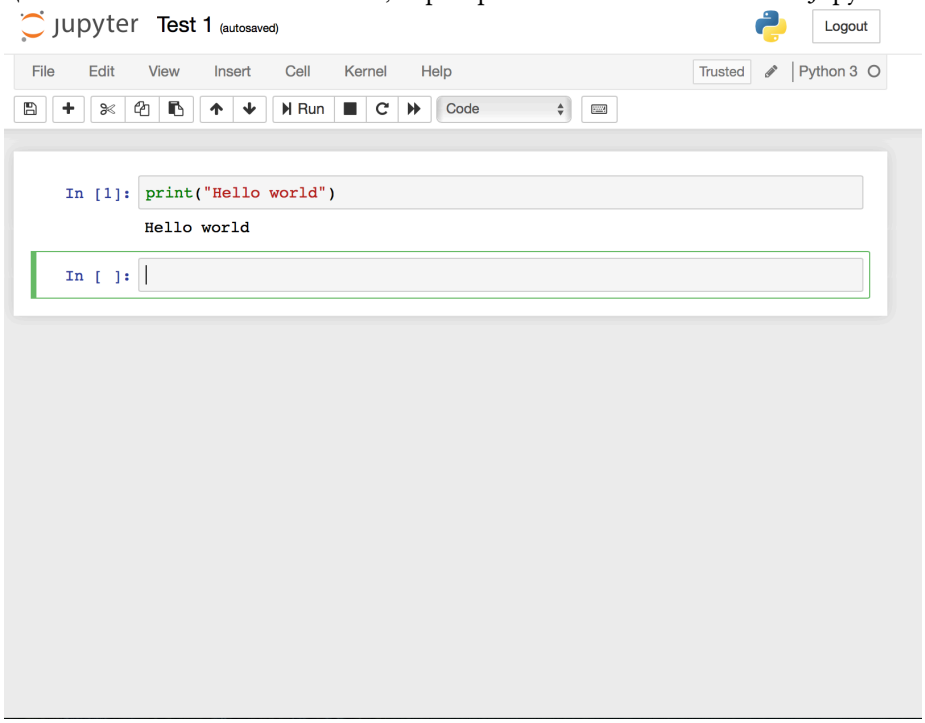

Interface.bb

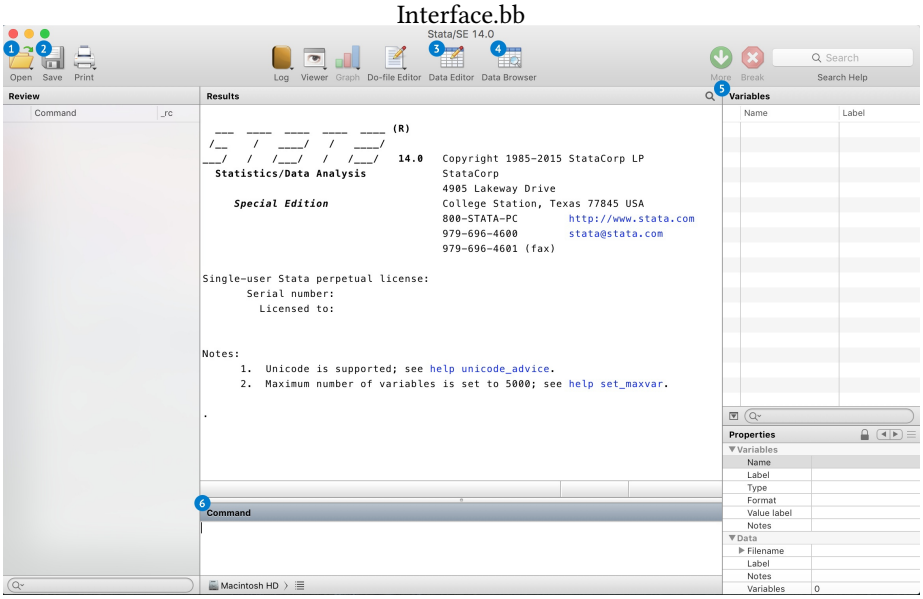

Рис. 2.2: *Интерфейс Stata*

###Программа STATA > Stata, в отличие от R и Python, является программой, а не языком программирования. Она также помогает в работе со статистическими данными.

#####Установка:

Для установки Stata необходимо загрузить актуальную версию с сайта компании-разработчика. Подойдут как Stata SE, так и Stata MP.

#####Начало работы:

1. **Open File** - открыть файл.
2. **Save** - сохранить файл.
3. **Data Editor** - редактирование данных.
4. **Data Browser** - просмотр данных.
5. **Variables** - список переменных.
6. **Command** - командная строка, в которой вводится код.

Глава 3

Коан о простой линейной регрессии

Построим простую линейную регрессию в R и проведем несложные тесты.

Загрузим необходимые пакеты.

```
library(tidyverse) # для манипуляций с данными и построения графиков
library(skimr) # для красивого summary
library(rio) # для чтения .dta файлов
library(car) # для линейных гипотез
library(tseries) # для теста на нормальность
library(sjPlot) # еще графики
```

Импортируем данные.

```
df = import("us-return.dta")
```

Исследуем наш датасет.

```
# skim_with(numeric = list(hist = NULL, p25 = NULL, p75 = NULL)) # опустим некоторые описательные характеристики
skim(df) # посмотрим на данные
```

Skim summary statistics
 n obs: 2664
 n variables: 22

-- Variable type:character ---
----
 variable missing complete   n min max empty n_unique
        B   0   2664 2664   0   6 2544   31

```
-- Variable type:numeric ------------------------------------------------------------------------
------------------------------------------------
 variable missing complete    n    mean      sd      p0     p25     p50
        A    2544      120 2664 60.5    34.79    1      30.75   60.5
    BOISE    2544      120 2664  0.017   0.097  -0.27   -0.045   0.015
   CITCRP    2544      120 2664  0.012   0.081  -0.28   -0.037   0.011
    CONED    2544      120 2664  0.019   0.05   -0.14   -0.012   0.019
   CONTIL    2544      120 2664 -0.0011  0.15   -0.6    -0.051   0
   DATGEN    2544      120 2664  0.0075  0.13   -0.34   -0.072   0.017
      DEC    2544      120 2664  0.02    0.099  -0.36   -0.051   0.024
    DELTA    2544      120 2664  0.012   0.096  -0.26   -0.053   0.013
   GENMIL    2544      120 2664  0.017   0.065  -0.15   -0.026   0.011
   GERBER    2544      120 2664  0.016   0.088  -0.29   -0.036   0.015
      IBM    2544      120 2664  0.0096  0.059  -0.19   -0.029   0.002
   MARKET    2544      120 2664  0.014   0.068  -0.26   -0.013   0.012
    MOBIL    2544      120 2664  0.016   0.08   -0.18   -0.032   0.013
    MOTOR    2544      120 2664  0.018   0.097  -0.33   -0.053   0.017
    PANAM    2544      120 2664  0.0035  0.13   -0.31   -0.065   0
     PSNH    2544      120 2664 -0.0042  0.11   -0.48   -0.049   0
   rkfree    2544      120 2664  0.0068  0.0022  0.0021  0.0052  0.0066
   RKFREE    2544      120 2664  0.0068  0.0022  0.0021  0.0052  0.0066
    TANDY    2544      120 2664  0.025   0.13   -0.25   -0.058   0.022
   TEXACO    2544      120 2664  0.012   0.08   -0.19   -0.037   0.01
    WEYER    2544      120 2664  0.0096  0.085  -0.27   -0.049  -0.002
     p75    p100     hist
  90.25   120     ▇▁▁▁▁▁▁▁
   0.07    0.38   ▇▁▁▁▁▁▁▁
  0.064    0.32   ▇▁▁▁▁▁▁▁
  0.045    0.15   ▇▁▁▁▁▁▁▁
  0.058    0.97   ▇▁▁▁▁▁▁▁
  0.078    0.53   ▇▁▁▁▁▁▁▁
  0.075    0.39   ▇▁▁▁▁▁▁▁
  0.063    0.29   ▇▁▁▁▁▁▁▁
   0.06    0.19   ▇▁▁▁▁▁▁▁
  0.065    0.23   ▇▁▁▁▁▁▁▁
   0.05    0.15   ▇▁▁▁▁▁▁▁
  0.062    0.15   ▇▁▁▁▁▁▁▁
  0.057    0.37   ▇▁▁▁▁▁▁▁
  0.084    0.27   ▇▁▁▁▁▁▁▁
  0.074    0.41   ▇▁▁▁▁▁▁▁
  0.043    0.32   ▇▁▁▁▁▁▁▁
 0.0078   0.013   ▇▁▁▁▁▁▁▁
 0.0078   0.013   ▇▁▁▁▁▁▁▁
  0.094    0.45   ▇▁▁▁▁▁▁▁
  0.048    0.4    ▇▁▁▁▁▁▁▁
   0.06    0.27   ▇▁▁▁▁▁▁▁
```

```
df = rename(df, n = A, date = B) # дадим столбцам более осмысленные названия
```

```
df = na.omit(df) # уберем строки с пропущенными наблюдениями
```

Будем верить в CAPM :) Оценим параметры модели для компании MOTOR. Соответственно, зависимая переменная - разница доходностей акций MOTOR и безрискового актива, а регрессор - рыночная премия.

```
#создаем новые переменные и добавляем их к набору данных
df = mutate(df, y = MOTOR - RKFREE, x = MARKET - RKFREE)
```

Строим нашу модель и проверяем гипотезу об адекватности регрессии.

```
ols = lm(y ~ x, data = df)
summary(ols)
```

```
Call:
lm(formula = y ~ x, data = df)

Residuals:
     Min       1Q   Median       3Q      Max
-0.168421 -0.059381 -0.003399  0.061373  0.182991

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.005253   0.007200   0.730    0.467
x           0.848150   0.104814   8.092 5.91e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.07844 on 118 degrees of freedom
Multiple R-squared:  0.3569,    Adjusted R-squared:  0.3514
F-statistic: 65.48 on 1 and 118 DF,  p-value: 5.913e-13
```

Вызовом одной функции получаем кучу полезных графиков. Можем визуально оценить наличие гетероскедастичности, нормальность распределения остатков, наличие выбросов.

```
plot(ols)
```

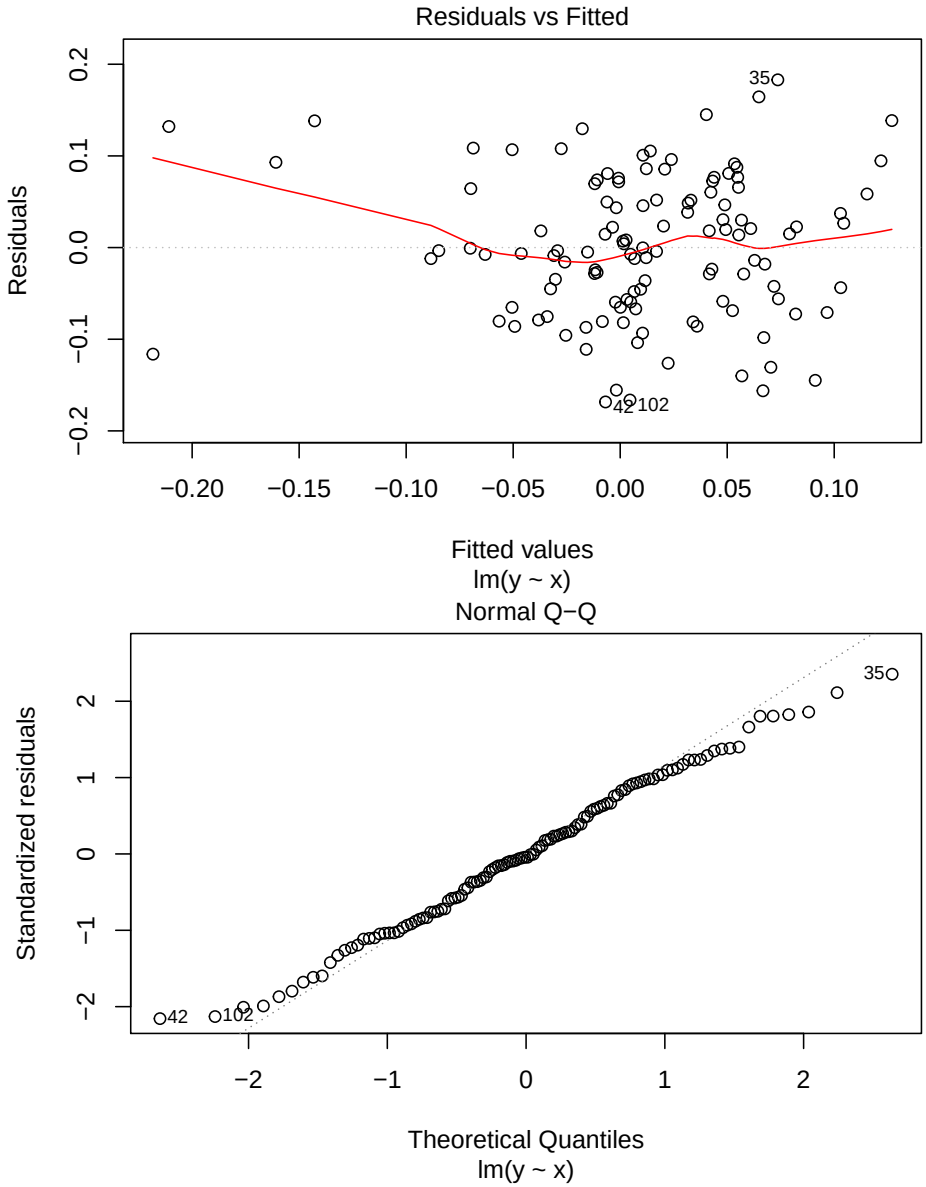
Residuals vs Fitted
Residuals
Fitted values
lm(y ~ x)
35
42
102
Normal Q−Q
Standardized residuals
Theoretical Quantiles
lm(y ~ x)

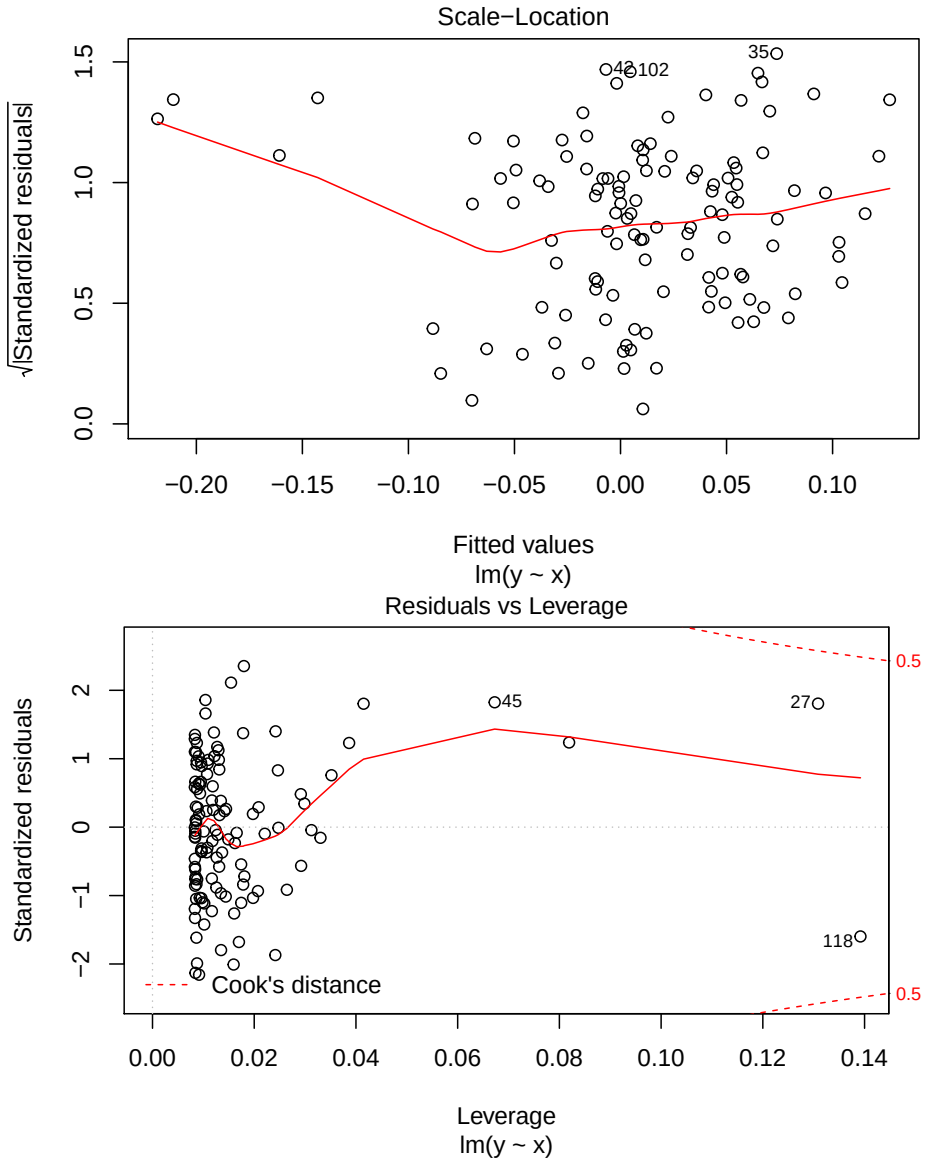

Строим доверительный интервал для параметров модели.

```
est = cbind(Estimate = coef(ols), confint(ols))
```

Проверим гипотезу о равенстве коэффициента при регрессоре единице.

```
linearHypothesis(ols, c("x = 1"))
```

Linear hypothesis test

Hypothesis:
x = 1

Model 1: restricted model
Model 2: y ~ x

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	119	0.73900			
2	118	0.72608	1	0.012915	2.0989	0.1501

Посмотрим на остатки :) Протестируем остатки регрессии на нормальность с помощью теста Харке-Бера.

$$H_0 : S = 0, K = 3,$$

где S — коэффициент асимметрии (Skewness), K — коэффициент эксцесса (Kurtosis)

```
jarque.bera.test(resid(ols))
```

Jarque Bera Test

data: resid(ols)
X-squared = 1.7803, df = 2, p-value = 0.4106

И тест Шапиро-Уилка.

$H_0 : \epsilon_i \sim N(\mu, \sigma^2)$

```
shapiro.test(resid(ols))
```

Shapiro-Wilk normality test

data: resid(ols)
W = 0.99021, p-value = 0.5531

Оба теста указывают на нормальность распределения остатков регрессии.

Сделаем прогноз модели по данным вне обучаемой выборки.

```
set.seed(7)
newData = df
newData = mutate(newData, x = x + rnorm(n = n())) # пошумим
yhat = predict(ols, newdata = newData, se = TRUE)
```

3.0.0.1. То же самое в стате

Загружаем данные.

use us-return.dta

end of do-file

Любуемся и даем новые названия столбцам.

```
summarize
ren A n
ren B date
```

```
    Variable |       Obs        Mean    Std. Dev.       Min        Max
-------------+--------------------------------------------------------
           A |       120        60.5    34.78505         1        120
           B |         0
       MOBIL |       120    .0161917    .0803075      -.178       .366
      TEXACO |       120    .0119417    .0797036      -.194       .399
         IBM |       120    .0096167     .059024      -.187        .15
-------------+--------------------------------------------------------
         DEC |       120     .01975    .0991438      -.364       .385
      DATGEN |       120    .0074833    .1275399      -.342       .528
       CONED |       120    .0185083    .0502719      -.139       .151
        PSNH |       120   -.0042167    .1094712      -.485       .318
       WEYER |       120    .0096333    .0850664      -.271        .27
-------------+--------------------------------------------------------
       BOISE |       120     .016675    .0974882      -.274       .379
       MOTOR |       120    .0181583    .0972656      -.331        .27
       TANDY |       120    .0250083     .127566      -.246       .454
       PANAM |       120    .0035167    .1318054      -.313       .406
       DELTA |       120    .0116917    .0959317       -.26       .289
-------------+--------------------------------------------------------
      CONTIL |       120     -.0011    .1506992        -.6       .974
      CITCRP |       120    .0118583    .0809719      -.282       .318
      GERBER |       120       .0164    .0877379      -.288       .234
      GENMIL |       120    .0165833    .0650403      -.148        .19
      MARKET |       120    .0139917    .0683532       -.26       .148
-------------+--------------------------------------------------------
      RKFREE |       120    .0068386    .0021869     .00207     .01255
      rkfree |       120    .0068386    .0021869     .00207     .01255
```

Убираем пропущенные значения и создаем новые переменные.

```
drop if n == .
gen y = MOTOR - RKFREE
gen x = MARKET - RKFREE
```

```
(2,544 observations deleted)
```

Строим модель и проверяем гипотезу об адекватности регрессии. Тут же получаем доверительные интервалы для коэффициентов.

```
reg y x
```

```
      Source |       SS           df       MS      Number of obs   =       120
-------------+----------------------------------   F(1, 118)       =     65.48
       Model |  .402913404         1  .402913404   Prob > F        =    0.0000
    Residual |  .726081541       118  .006153233   R-squared       =    0.3569
-------------+----------------------------------   Adj R-squared   =    0.3514
       Total |  1.12899494       119  .009487352   Root MSE        =    .07844

------------------------------------------------------------------------------
           y |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
           x |   .8481496   .1048138     8.09   0.000     .6405898    1.055709
       _cons |   .0052529   .0071999     0.73   0.467     -.009005    .0195107
------------------------------------------------------------------------------
```

Проверим гипотезу о равенстве коэффициента при регрессоре единице.

```
test x = 1
```

```
 ( 1)  x = 1

       F(  1,   118) =    2.10
            Prob > F =    0.1501
```

Сделаем предсказание по выборке и сохраним остатки.

```
predict u_hat, resid
predict y_hat
```

```
(option xb assumed; fitted values)
```

Протестируем остатки регрессии на нормальность с помощью теста Харке-Бера. На самом деле, это не совсем тест Харке-Бера. Оригинальный вариант ассимптотический и в нем нет поправки на размер выборки. В Stata есть. Подробнее здесь https://www.stata.com/manuals13/rsktest.pdf

```
sktest u_hat
```

```
                    Skewness/Kurtosis tests for Normality
                                                  ------ joint ------
    Variable |       Obs  Pr(Skewness)  Pr(Kurtosis) adj chi2(2)   Prob>chi2
-------------+-------------------------------------------------------------
       u_hat |       120     0.8841        0.1027        2.74         0.2539
```

И тест Шапиро-Уилка. Тут все аналогично R.

```
swilk u_hat
```

```
                Shapiro-Wilk W test for normal data

    Variable |       Obs       W           V       z       Prob>z
-------------+--------------------------------------------------------
       u_hat |       120    0.99021       0.942   -0.133    0.55310
```

Гипотеза о нормальности остатков не отвергается.

QQ - график

qnorm u_hat

График предсказанных значений против остатков.

```stata
rvfplot, yline(0)
```

График диагональных элементов матрицы-шляпницы против квадрата остатков (по сравнению с R оси поменялись местами).

lvr2plot

График предсказанных значений против стандартизиованных остатков. Размер точек на графике зависит от расстоя

```stata
predict D, cooksd
predict standard, rstandard

graph twoway scatter standard y_hat [aweight=D], msymbol(oh) yline(0)
```

```

```

```stata
set seed 7

set obs 120
gen x_new = x+ 0.5 *rnormal()
gen y_hat_new =  .8481496 * x_new+ .0052529
```

```
```

number of observations (_N) was 120, now 120

```
#### То же самое в python

Много хорошихх функций для статистических расчетов можно найти в пакете Statsmodels.

```python

import pandas as pd # для работы с таблицами
import numpy as np # математика, работа с матрицами
import matplotlib.pyplot as plt # графики
import statsmodels.api as sm
import statsmodels.formula.api as smf
import statsmodels.graphics.gofplots as gf
from statsmodels.stats.outliers_influence import summary_table
import seaborn as sns # еще более классные графики
from scipy.stats import shapiro # еще математика
import statsmodels.discrete.discrete_model
```

При желании, можем кастомизировать графики :)

```python
plt.style.use('seaborn')
plt.rc('font', size=14)
plt.rc('figure', titlesize=15)
plt.rc('axes', labelsize=15)
plt.rc('axes', titlesize=15)
```

Загрузим данные.

```python
df = pd.read_stata('us-return.dta')
```

Избавимся от наблюдений с пропущенными значенями.

```python
df.dropna(inplace=True) ##ИСПРАВИТЬ (выкинуть только пропуски целевой и объяснющей)
df.reset_index(drop=True, inplace=True)
```

Переименуем столбцы.
```

```python
df = df.rename(columns={'A':'n', 'B': 'date'})
```

```python
df['y'] = df['MOTOR'] - df['RKFREE']
df['x'] = df['MARKET'] - df['RKFREE']
```

Строим модель и читаем саммари :)

```python
regr = smf.ols('y~x', data = df).fit()
regr.summary()
```

```
<class 'statsmodels.iolib.summary.Summary'>
"""
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:                       0.357
Model:                            OLS   Adj. R-squared:                  0.351
Method:                 Least Squares   F-statistic:                     65.48
Date:                Пн, 16 сен 2019   Prob (F-statistic):           5.91e-13
Time:                        15:59:27   Log-Likelihood:                136.18
No. Observations:                 120   AIC:                            -268.4
Df Residuals:                     118   BIC:                            -262.8
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept      0.0053      0.007      0.730      0.467      -0.009       0.020
x              0.8481      0.105      8.092      0.000       0.641       1.056
==============================================================================
Omnibus:                        2.684   Durbin-Watson:                   2.030
Prob(Omnibus):                  0.261   Jarque-Bera (JB):                1.780
Skew:                          -0.031   Prob(JB):                        0.411
Kurtosis:                       2.406   Cond. No.                         14.6
==============================================================================

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
"""
```

```

Получить прогноз.

```python
df['yhat'] = regr.fittedvalues
```

Красивые графики для остатков, выборосов и прочих радостей, как в R, придется строить ручками. Зато г

```python
fig, ax = plt.subplots()
ax.plot(df['x'],regr.fittedvalues, color='g', alpha =0.8)
ax.scatter(df['x'],regr.fittedvalues+regr.resid, color = 'g', alpha = 0.8, s = 40)
ax.vlines(df['x'],regr.fittedvalues,regr.fittedvalues+regr.resid, color = 'gray', alpha = 0.5)
plt.title('Линия регрессии и остатки')
plt.xlabel('RKFREE')
plt.ylabel('MARKET')
plt.show()
```


Строим доверительный интервал.

```python
regr.conf_int()
```

```
                0         1
Intercept -0.009005  0.019511
x          0.640590  1.055709
```

И проведем F-test.

```python
hypotheses = '(x = 1)'
regr.f_test(r_matrix = hypotheses)
```

```
<class 'statsmodels.stats.contrast.ContrastResults'>
<F test: F=array([[2.09891771]]), p=0.1500556415866233, df_denom=118, df_num=1>
```
```

Тест Шапиро. Такой же, как и в R. Для удобства можно поместить в табличку.

```python
W, p_value = shapiro(regr.resid)
#pd.DataFrame(data = {'W': [round(W,3)], 'p_value': [round(p_value,3)]})
```

Генерируем новые данные и строим предсказание.

```python
import random
random.seed(7)

newData = df['x'] + 0.5*np.random.normal(len(df))
prediction = regr.predict(newData)
```

А теперь жесть! Построим графички, похожие на autoplot R.

```python
fig_1 = plt.figure(1)

fig_1.axes[0] = sns.residplot(df['x'], df['y'],
                              lowess=True,
                              scatter_kws={'alpha': 0.6},
                              line_kws={'color': 'red', 'lw': 2, 'alpha': 0.8})

fig_1.axes[0].set_title('Residuals vs Fitted')
fig_1.axes[0].set_xlabel('Fitted values')
fig_1.axes[0].set_ylabel('Residuals')


#можем добавить метки потенциальных аутлаеров
abs_resid = abs(regr.resid).sort_values(ascending=False)
abs_resid_top3 = abs_resid[:3]

for i in abs_resid_top3.index:
   fig_1.axes[0].annotate(i,
                          xy=(regr.fittedvalues[i],
                              regr.resid[i]))
```

```python
norm_residuals = regr.get_influence().resid_studentized_internal #сохраним стьюдентизированные остатки


QQ = gf.ProbPlot(norm_residuals)
fig_2 = QQ.qqplot(line='45', alpha=0.5, color='b', lw=1)


fig_2.axes[0].set_title('Normal Q-Q')
fig_2.axes[0].set_xlabel('Theoretical Quantiles')
fig_2.axes[0].set_ylabel('Standardized Residuals');

#и снова метки
abs_norm_resid = np.flip(np.argsort(abs(norm_residuals)), 0)
abs_norm_resid_top3 = abs_norm_resid[:3]

for r, i in enumerate(abs_norm_resid_top3):
   fig_2.axes[0].annotate(i,
                          xy=(np.flip(QQ.theoretical_quantiles, 0)[r],
                              norm_residuals[i]))
```

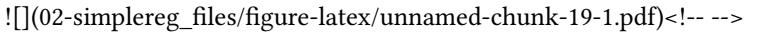

```python
fig_3 = plt.figure(3)

plt.scatter(regr.fittedvalues, np.sqrt(abs(norm_residuals)), alpha=0.5)
sns.regplot(regr.fittedvalues, np.sqrt(abs(norm_residuals)),
            scatter=False,
            ci=False,
            lowess=True,
            line_kws={'color': 'red', 'lw': 1, 'alpha': 0.6})

fig_3.axes[0].set_title('Scale-Location')
fig_3.axes[0].set_xlabel('Fitted values')
fig_3.axes[0].set_ylabel('$\sqrt{|Standardized Residuals|}$')

# и еще раз!)
abs_sq_norm_resid = np.flip(np.argsort(np.sqrt(abs(norm_residuals)), 0))
abs_sq_norm_resid_top3 = abs_sq_norm_resid[:3]
```

```
for i in abs_sq_norm_resid_top3:
   fig_3.axes[0].annotate(i, xy=(regr.fittedvalues[i],
                          np.sqrt(abs(norm_residuals)[i])))
```

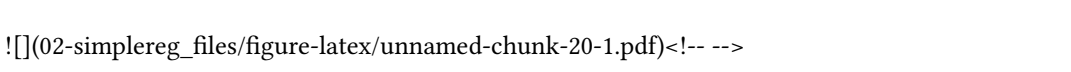

```python
leverage = regr.get_influence().hat_matrix_diag #сохраняем элементы матрицы-шляпницы
cook_dist = regr.get_influence().cooks_distance[0] #И расстояние Кука

fig_4 = plt.figure(4)

plt.scatter(leverage, norm_residuals, alpha=0.5)
sns.regplot(leverage, norm_residuals,
          scatter=False,
          ci=False,
          lowess=True,
          line_kws={'color': 'red', 'lw': 1, 'alpha': 0.8})

fig_4.axes[0].set_xlim(0, 0.20)
```

```
(0, 0.2)
```

```python
fig_4.axes[0].set_ylim(-3, 5)
```

```
(-3, 5)
```

```python
fig_4.axes[0].set_title('Residuals vs Leverage')
fig_4.axes[0].set_xlabel('Leverage')
fig_4.axes[0].set_ylabel('Standardized Residuals')


leverage_top3 = np.flip(np.argsort(cook_dist), 0)[:3]
```

```
for i in leverage_top3:
   fig_4.axes[0].annotate(i,
                          xy=(leverage[i],
                              norm_residuals[i]))
plt.show()
```

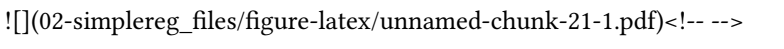

<!--chapter:end:02-simplereg.Rmd-->

Модели бинарного выбора {#binchoice}

<!--chapter:end:03-binchoice.Rmd-->

Модели упорядоченного выбора и условный логит {#ordchoice}

Загрузим необходимые пакеты.

```r
library(tidyverse) # для манипуляций с данными и построения графиков
library(skimr) #для красивого summary
library(rio) # для чтения .dta файлов
library(margins)
```

```
Error in library(margins): there is no package called 'margins'
```

```r
library(mlogit)
```

```
Error in library(mlogit): there is no package called 'mlogit'
```

```r
library(nnet)
library(questionr)
```

```

```

```
Error in library(questionr): there is no package called 'questionr'
```

```r
library(MASS)
library(survival)

# log(6)
```

Импортируем датасет. В нем находятся данные по клиентам пенсионных фондов. Нас интересует переменная `pctst
в зависимости от ответа респондента на вопрос о предпочтительном способе инвестирования пенсионных накоплен

```r
df = rio::import("pension.dta")
```

```r
skim_with(numeric = list(hist = NULL, p25 = NULL, p75 = NULL)) #посмотрим на данные
#skim(df)
```

Создадим факторную перменную и упорядочим категории.

```r
df = rename(df,  alloc = pctstck) # переименуем
df = mutate(df, alloc_factor = factor(alloc)) # факторная переменная
df = mutate(df, y = relevel(df$alloc_factor, ref = 1)) # сменить базовую категорию
levels(df$y)
```

```
[1] "0"   "50"  "100"
```

Построим модель множественного выбора (лог-линейная модель).

```r
multmodel = multinom(y ~ choice+age+educ+wealth89+prftshr, data = df)
```

```
# weights:  21 (12 variable)
initial  value 220.821070
iter  10 value 207.012642
iter  20 value 204.507792
final  value 204.507779
converged
```

```r
summary(multmodel)
```

```
Call:
multinom(formula = y ~ choice + age + educ + wealth89 + prftshr,
    data = df)

Coefficients:
    (Intercept)    choice        age       educ     wealth89    prftshr
50     3.777686 0.6269410 -0.10621691 0.18518113 -0.0003716626 -0.2717872
100    4.492971 0.6244954 -0.09482129 0.04644315 -0.0003548369  0.9809245

Std. Errors:
    (Intercept)    choice        age       educ     wealth89   prftshr
50     1.581691 0.3701263 0.02826469 0.06725443 0.0007365833 0.4988234
100    1.385291 0.3851273 0.02530600 0.07203058 0.0007896235 0.4396202

Residual Deviance: 409.0156
AIC: 433.0156
```

Сохраним прогнозы.

```r
fit_values = fitted(multmodel)
head(fit_values)
```

```
         0        50       100
1 0.4040703 0.3308134 0.2651163
2 0.1534943 0.2619464 0.5845593
3 0.1651913 0.2342525 0.6005562
4 0.4300671 0.1504960 0.4194370
```

```
5 0.4878942 0.2797337 0.2323721
6 0.4642700 0.1265789 0.4091510
```

И посчитать относительное изменение отношения шансов:

$$
\frac{P(y_{i} = j)}{P(y_{i} = 1)} = exp(x_{i}\beta)
$$
показывает изменение отношения шансов при выборе альтернативы j вместо альтернативы 0, если x изменился на е

```r
odds.ratio(multmodel) # отношение шансов в stata называется relative-risk ratio
```

```
Error in odds.ratio(multmodel): could not find function ”odds.ratio”
```

Можем посчитать предельные эффекты в различных квартилях.

```r
summary(marginal_effects(multmodel)) # mean как в стате
```

```
Error in marginal_effects(multmodel): could not find function ”marginal_effects”
```

Допустим, мы можем упорядочить наши альтернативы (например, от более рискованного способа распределения ре

```r
ordered_logit = polr(y ~ choice+age+educ+wealth89+prftshr , data = df)
ordered_probit = polr(y ~ choice+age+educ+wealth89+prftshr , data = df, method = 'probit')

fit_prob = fitted(ordered_probit)
fit_log = fitted(ordered_logit)
ordered_probit
```

```
Call:
polr(formula = y ~ choice + age + educ + wealth89 + prftshr,
```

```
   data = df, method = ”probit”)

Coefficients:
      choice          age         educ      wealth89       prftshr
 0.2932276690 -0.0453064786  0.0269376562 -0.0001693805  0.4864824791

Intercepts:
     0|50     50|100
-2.578050 -1.561799

Residual Deviance: 425.7763
AIC: 439.7763
(25 observations deleted due to missingness)
```

```r
ln(5)
```

```
Error in ln(5): could not find function ”ln”
```

```r
cond_logit = clogit(y ~ choice+age+strata(educ)+wealth89+prftshr , data = df)
```

```
Error in coxph(formula = Surv(rep(1, 226L), y) ~ choice + age + strata(educ) + : Cox model doesn't support ”mright”
```

То же самое в стате

```stata
use pension.dta
```

```
end of do-file
```

```stata
sum
```

```
    Variable |       Obs        Mean    Std. Dev.       Min        Max
-------------+--------------------------------------------------------
          id |       226    2445.093    1371.271        38       5014
      pyears |       218    11.38532    9.605498         0         45
     prftshr |       206    .2087379    .4073967         0          1
      choice |       226    .6150442     .487665         0          1
      female |       226    .6017699      .49062         0          1
-------------+--------------------------------------------------------
     married |       226    .7345133    .4425723         0          1
         age |       226    60.70354    4.287002        53         73
        educ |       219    13.51598    2.554627         8         18
      finc25 |       216    .2083333    .4070598         0          1
      finc35 |       216    .1851852     .38935         0          1
-------------+--------------------------------------------------------
      finc50 |       216    .2453704    .4313061         0          1
      finc75 |       216        .125    .3314871         0          1
     finc100 |       216    .1203704     .32615         0          1
     finc101 |       216    .0648148    .2467707         0          1
    wealth89 |       226    197.9057    242.0919   -579.997   1484.997
-------------+--------------------------------------------------------
       black |       226    .119469    .3250596         0          1
    stckin89 |       226    .3185841    .4669616         0          1
     irain89 |       226          .5    .5011099         0          1
     pctstck |       226    46.68142    39.44116         0        100
```

```stata
ren pctstck alloc
```

Построим модель множественного выбора (лог-линейная модель).

mlogit alloc choice age educ wealth89 prftshr, baseoutcome(0) #маленькое отличие с R

> ичие с R
option # not allowed
r(198);

end of do-file
r(198);

Можем посмотреть на прогнозы.

predict p1 p2 p3, p

option # not allowed
r(198);

last estimates not found
r(301);

end of do-file
r(301);

И посчитать относительное изменение отношения шансов:

$$\frac{P(y_i = j)}{P(y_i = 1)} = exp(x_i\beta)$$

- показывает изменение отношения шансов при выборе альтернативы j вместо альтернативы 0, если x изменился на единицу

mlogit, rrr #relative-risk ratio

option # not allowed
r(198);

last estimates not found
r(301);

end of do-file
r(301);

Можем посчитать предельные эффекты в разных точках.

margins, predict(outcome(50)) dydx(choice age educ wealth89 prftshr) atmeans

margins, predict(outcome(50)) dydx(choice age educ wealth89 prftshr) at((p25) *)

option # not allowed
r(198);

last estimates not found
r(301);

end of do-file
r(301);

```
oprobit alloc choice age educ wealth89 prftshr

ologit alloc choice age educ wealth89 prftshr

 option # not allowed
r(198);



Iteration 0:   log likelihood = -219.86356
Iteration 1:   log likelihood = -212.89234
Iteration 2:   log likelihood = -212.88817
Iteration 3:   log likelihood = -212.88817

Ordered probit regression                       Number of obs     =        201
                                                LR chi2(5)        =      13.95
                                                Prob > chi2       =     0.0159
Log likelihood = -212.88817                     Pseudo R2         =     0.0317

------------------------------------------------------------------------------
       alloc |      Coef.   Std. Err.      z    P>|z|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
      choice |   .2932272    .167064     1.76   0.079    -.0342122    .6206666
         age |  -.0453065   .0195009    -2.32   0.020    -.0835275   -.0070854
        educ |   .0269375   .0315643     0.85   0.393    -.0349273    .0888024
    wealth89 |  -.0001694   .0003431    -0.49   0.622    -.0008419    .0005031
     prftshr |   .4864833   .2030406     2.40   0.017     .088531    .8844355
-------------+----------------------------------------------------------------
       /cut1 |  -2.578052   1.277878                     -5.082648   -.0734562
       /cut2 |  -1.561798   1.272756                     -4.056353    .9327576
------------------------------------------------------------------------------



Iteration 0:   log likelihood = -219.86356
Iteration 1:   log likelihood = -212.75117
Iteration 2:   log likelihood = -212.72813
Iteration 3:   log likelihood = -212.72813

Ordered logistic regression                     Number of obs     =        201
                                                LR chi2(5)        =      14.27
                                                Prob > chi2       =     0.0140
Log likelihood = -212.72813                     Pseudo R2         =     0.0325

------------------------------------------------------------------------------
       alloc |      Coef.   Std. Err.      z    P>|z|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
```

```
      choice |   .4720438   .2757545     1.71   0.087    -.068425    1.012513
         age |  -.0776337   .0328659    -2.36   0.018   -.1420497   -.0132177
        educ |   .0475714   .0514763     0.92   0.355   -.0533203    .1484631
    wealth89 |   -.000277    .000561    -0.49   0.621   -.0013765    .0008224
     prftshr |   .8312158   .3506528     2.37   0.018    .1439489    1.518483
-------------+----------------------------------------------------------------
       /cut1 |  -4.376271   2.144494                     -8.579402   -.1731395
       /cut2 |  -2.714186   2.129423                     -6.887779    1.459407
------------------------------------------------------------------------------
```

Посмотрим на conditional logit

ПОКА ЗАБИЛА

```
use crackers.dta


egen resp = group(id occ)

tabulate brand, generate(br)
rename br1 Sunshine
rename br2 Keebler
rename br3 Nabisco

clogit choice Sunshine Keebler Nabisco display feature price, group(resp)

 option # not allowed
r(198);


no; data in memory would be lost
r(4);

end of do-file
r(4);
```

Глава 4

Модели счетных данных

Загрузим необходимые пакеты.

```
library(tidyverse) #работа с данными и графики
library(skimr) #красивое summary
library(rio) #чтение .dta файлов
library(vcd) #еще графики
library(MASS) #отрицательное биномиальное
library(lmtest) #для проверки гипотез
library(pscl) #zero-inflation function
```

Error in library(pscl): there is no package called 'pscl'

```
library(margins) #для подсчета предельных эффектов
```

Error in library(margins): there is no package called 'margins'

Импортируем данные.

```
df = import(file = "fish.dta")
```

Данные содержат информацию о количестве рыбы, пойманной людьми на отдыхе.

Camper - наличие/отсутсвие палатки. Child - количество детей, которых взяли на рыбалку. Persons - количество людей в группе. Count - количество пойманной рыбы

Посмотрим нам описательные статистики.

```
skim_with(numeric = list(hist = NULL, p25 = NULL, p75 = NULL))
skim(df)
```

Skim summary statistics
 n obs: 250

```
 n variables: 4

-- Variable type:numeric ------------------------------------------------------------------------
-------------------------------------------------
 variable missing complete   n mean    sd p0 p50 p100
   camper       0      250 250 0.59  0.49  0   1    1
    child       0      250 250 0.68  0.85  0   0    3
    count       0      250 250 3.3  11.64  0   0  149
  persons       0      250 250 2.53  1.11  1   2    4
```

Переменная camper принимает всего два значения, поэтому превратим ее в факторную переменную.

```
df = mutate(df, camper = factor(camper))
```

Наша задача - по имеющимся данным предсказать улов. Для начала посмотрим на распределение объясняемой переменной count.

```
ggplot(df, aes(x = count)) + geom_histogram(binwidth = 1) + labs(x = 'count', y = 'frequency', title = 'Distribution
```

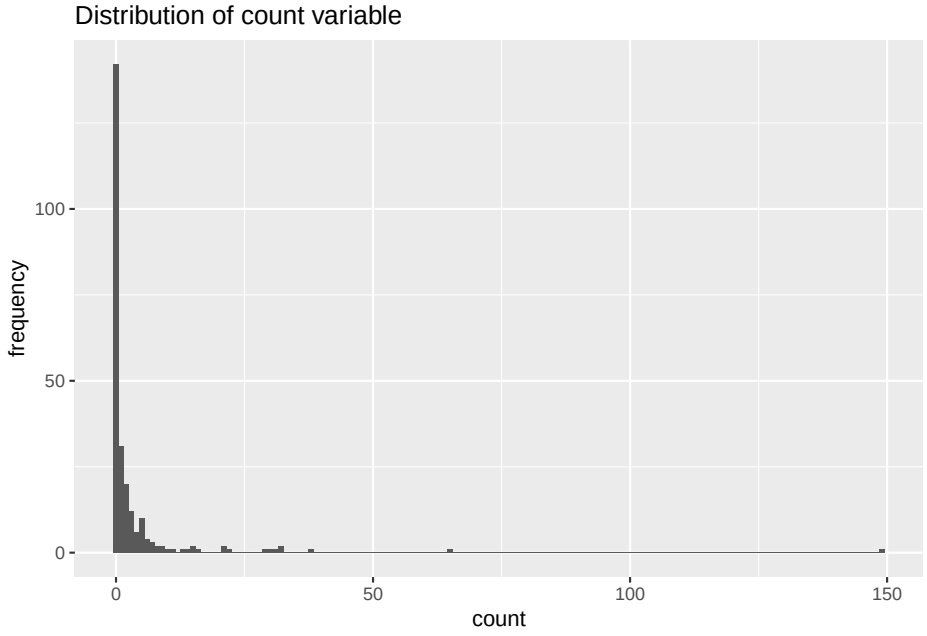

Предположим, что переменная имеет распределение Пуассона. Будем использовать пуассоновскую регрессию.

$$P(y = k) = exp(-\lambda)\lambda^k/k!$$

где $\lambda = \exp(b_1 + b_2 * x)$

```
poisson = glm(count ~ child + camper +  persons, family = "poisson", data = df)
summary(poisson)
```

```
Call:
glm(formula = count ~ child + camper + persons, family = "poisson",
    data = df)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-6.8096  -1.4431  -0.9060  -0.0406  16.1417

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -1.98183    0.15226  -13.02   <2e-16 ***
child       -1.68996    0.08099  -20.87   <2e-16 ***
camper1      0.93094    0.08909   10.45   <2e-16 ***
persons      1.09126    0.03926   27.80   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 2958.4  on 249  degrees of freedom
Residual deviance: 1337.1  on 246  degrees of freedom
AIC: 1682.1

Number of Fisher Scoring iterations: 6
```

Посчитаем средний предельный эффект для каждой переменной.

```
colMeans(marginal_effects(poisson))
```

```
Error in marginal_effects(poisson): could not find function "marginal_effects"
```

Однако, заметим, что дисперсия и среднее значение объясняемой переменной не равны, как это предполагает распределение Пуассона.

```
df %>% group_by(camper) %>% summarize(var = var(count), mean = mean(count))
```

```
# A tibble: 2 x 3
  camper   var  mean
  <fct>  <dbl> <dbl>
1 0       21.1  1.52
2 1      212.   4.54
```

Оценим регрессию, предполагая отрицательное биномиальное распределение остатков. В этом случае, дисперсия распределения зависит от некоторого па-

раметра и не равна среднему.

```
nb1 = glm.nb(count ~ child + camper +  persons, data = df)
summary(nb1)
```

```
Call:
glm.nb(formula = count ~ child + camper + persons, data = df,
    init.theta = 0.4635287626, link = log)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.6673  -0.9599  -0.6590  -0.0319   4.9433

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -1.6250     0.3304  -4.918 8.74e-07 ***
child        -1.7805     0.1850  -9.623  < 2e-16 ***
camper1       0.6211     0.2348   2.645  0.00816 **
persons       1.0608     0.1144   9.273  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(0.4635) family taken to be 1)

    Null deviance: 394.25  on 249  degrees of freedom
Residual deviance: 210.65  on 246  degrees of freedom
AIC: 820.44

Number of Fisher Scoring iterations: 1

              Theta:  0.4635
          Std. Err.:  0.0712

 2 x log-likelihood:  -810.4440
```

Попробуем исключить из модели переменную camper и сравним качество двух моделей.

```
nb2 = update(nb1, . ~ . - camper)
waldtest(nb1, nb2)
```

```
Wald test

Model 1: count ~ child + camper + persons
Model 2: count ~ child + persons
  Res.Df Df      F   Pr(>F)
```

```
1    246
2    247 -1 6.9979 0.008686 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Можем посмотреть на результаты модели с “раздутыми нулями” (zero-inflated). Они предполагают большую частоту нулевых наблюдений.

```
zero_infl = zeroinfl(count ~ child + camper | persons, data = df, dist = 'negbin')
```

```
Error in zeroinfl(count ~ child + camper | persons, data = df, dist = "negbin"): could not find function "zeroinfl"
```

```
summary(zero_infl)
```

```
Error in summary(zero_infl): object 'zero_infl' not found
```

4.0.0.1. То же самое в стате

Загружаем данные и смотрим описательные статистики.

```
use fish.dta
summarize
```

```
    Variable |       Obs        Mean    Std. Dev.       Min        Max
-------------+--------------------------------------------------------
      camper |       250        .588    .4931824         0          1
       child |       250        .684    .8503153         0          3
       count |       250       3.296    11.63503         0        149
     persons |       250       2.528     1.11273         1          4
```

```
hist count
```

(bin=15, start=0, width=9.9333333)

Строим Пуассоновскую регрессию. В описательных статистиках: $AIC = -2log(L) + 2k$ $AIC = -2log(L) + klog(N)$

```
glm count camper child persons, family(poisson)
```

```
Iteration 0:   log likelihood = -965.92815
Iteration 1:   log likelihood = -837.97093
Iteration 2:   log likelihood = -837.07307
Iteration 3:   log likelihood = -837.07248
Iteration 4:   log likelihood = -837.07248

Generalized linear models                         No. of obs      =        250
Optimization     : ML                             Residual df     =        246
                                                  Scale parameter =          1
Deviance         =  1337.079644                   (1/df) Deviance =   5.435283
Pearson          =  2910.627049                   (1/df) Pearson  =   11.83182
```

```
Variance function: V(u) = u                  [Poisson]
Link function    : g(u) = ln(u)              [Log]

                                             AIC           =    6.72858
Log likelihood   = -837.0724803              BIC           =  -21.19974

------------------------------------------------------------------------------
             |                 OIM
       count |      Coef.   Std. Err.      z    P>|z|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
      camper |   .9309359   .0890869    10.45   0.000     .7563289    1.105543
       child |  -1.689957   .0809922   -20.87   0.000    -1.848699   -1.531215
     persons |   1.091262   .0392553    27.80   0.000     1.014323    1.168201
       _cons |  -1.981827    .152263   -13.02   0.000    -2.280257   -1.683397
------------------------------------------------------------------------------
```

Можем посчитать AIC и BIC по другой формуле, аналогично выводу R. $AIC = \frac{-2log(L)+2k}{N}$

estat ic

Akaike's information criterion and Bayesian information criterion

```
------------------------------------------------------------------------------
       Model |       Obs  ll(null)  ll(model)      df        AIC        BIC
-------------+----------------------------------------------------------------
           . |       250         .  -837.0725       4   1682.145   1696.231
------------------------------------------------------------------------------
               Note: N=Obs used in calculating BIC; see [R] BIC note.
```

Посмотрим, равны ли среднее значение и дисперсия, как это предполагает распределение Пуассона.

tabstat count, by(camper) stat(mean, variance) nototal

```
Summary for variables: count
    by categories of: camper (CAMPER)

  camper |      mean  variance
---------+--------------------
       0 |  1.524272  21.05578
       1 |  4.537415   212.401
-------------------------------
```

Предположим, что остатки имеют отрицательное биномиальное распределение.

nbreg count child camper persons

```
Fitting Poisson model:

Iteration 0:   log likelihood = -841.58831
Iteration 1:   log likelihood = -837.07386
Iteration 2:   log likelihood = -837.07248
Iteration 3:   log likelihood = -837.07248

Fitting constant-only model:

Iteration 0:   log likelihood = -582.76028
Iteration 1:   log likelihood = -464.44518
Iteration 2:   log likelihood = -464.43931
Iteration 3:   log likelihood = -464.43931

Fitting full model:

Iteration 0:   log likelihood = -438.02759
Iteration 1:   log likelihood = -409.71171
Iteration 2:   log likelihood = -405.34765
Iteration 3:   log likelihood = -405.22204
Iteration 4:   log likelihood =   -405.222
Iteration 5:   log likelihood =   -405.222

Negative binomial regression                    Number of obs     =        250
                                                LR chi2(3)        =     118.43
Dispersion     = mean                           Prob > chi2       =     0.0000
Log likelihood =   -405.222                     Pseudo R2         =     0.1275

------------------------------------------------------------------------------
       count |      Coef.   Std. Err.      z    P>|z|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       child |   -1.78052   .1920379    -9.27   0.000    -2.156907   -1.404132
      camper |   .6211286   .2358072     2.63   0.008      .158955    1.083302
     persons |     1.0608   .1174733     9.03   0.000     .8305564    1.291043
       _cons |   -1.62499   .3294006    -4.93   0.000    -2.270603   -.9793765
-------------+----------------------------------------------------------------
   /lnalpha |   .7688868   .1538497                      .4673469    1.070427
-------------+----------------------------------------------------------------
      alpha |   2.157363   .3319098                      1.595755    2.916624
------------------------------------------------------------------------------
LR test of alpha=0: chibar2(01) = 863.70                   Prob >= chibar2 = 0.000
```

Проверим гипотезу о равенстве 0 коэффицинта при переменной camper. Проведем тест Вальда.

```
quietly: nbreg count child i.camper persons #скрыть вывод регрессии
test i.camper
```

```
# invalid name
r(198);

end of do-file
r(198);
```

Посчитаем средний предельный эффект для каждоый переменной.

```
margins, dydx(*)

 # invalid name
r(198);



Average marginal effects                        Number of obs     =        250
Model VCE    : OIM

Expression   : Predicted number of events, predict()
dy/dx w.r.t. : child camper persons

------------------------------------------------------------------------------
             |            Delta-method
             |      dy/dx   Std. Err.      z    P>|z|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
       child |  -5.842234   1.494053    -3.91   0.000    -8.770524   -2.913943
      camper |   2.038045   .8917015     2.29   0.022     .2903418    3.785748
     persons |   3.480692   .9200607     3.78   0.000     1.677406    5.283978
------------------------------------------------------------------------------
```

И модель с раздутыми нулями.

```
zinb count child i.camper, inflate(persons)

 # invalid name
r(198);



Fitting constant-only model:

Iteration 0:   log likelihood = -519.33992
Iteration 1:   log likelihood = -471.96077
Iteration 2:   log likelihood = -465.38193
Iteration 3:   log likelihood = -464.39882
Iteration 4:   log likelihood = -463.92704
Iteration 5:   log likelihood = -463.79248
Iteration 6:   log likelihood = -463.75773
Iteration 7:   log likelihood =  -463.7518
```

```
Iteration 8:   log likelihood = -463.75119
Iteration 9:   log likelihood = -463.75118

Fitting full model:

Iteration 0:   log likelihood = -463.75118  (not concave)
Iteration 1:   log likelihood = -440.43162
Iteration 2:   log likelihood = -434.96651
Iteration 3:   log likelihood = -433.49903
Iteration 4:   log likelihood = -432.89949
Iteration 5:   log likelihood = -432.89091
Iteration 6:   log likelihood = -432.89091

Zero-inflated negative binomial regression      Number of obs     =        250
                                                Nonzero obs       =        108
                                                Zero obs          =        142

Inflation model = logit                         LR chi2(2)        =      61.72
Log likelihood  = -432.8909                     Prob > chi2       =     0.0000

------------------------------------------------------------------------------
       count |      Coef.   Std. Err.      z    P>|z|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
count        |
       child |  -1.515255   .1955912    -7.75   0.000    -1.898606   -1.131903
       _cons |   1.371048   .2561131     5.35   0.000     .8690758    1.873021
-------------+----------------------------------------------------------------
inflate      |
     persons |  -1.666563   .6792833    -2.45   0.014    -2.997934   -.3351922
       _cons |   1.603104   .8365065     1.92   0.055    -.036419    3.242626
-------------+----------------------------------------------------------------
    /lnalpha |   .9853533    .17595     5.60   0.000     .6404975    1.330209
-------------+----------------------------------------------------------------
       alpha |   2.678758   .4713275                      1.897425    3.781834
------------------------------------------------------------------------------
```

4.0.0.2. То же самое в python

Нужные пакетики:

```
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
plt.style.use('ggplot')
```

Загружаем данные и смотрим описательные статистики.

```
df_fish = pd.read_stata('fish.dta')
```

```
sns.distplot(df_fish['count'])
plt.show()
```

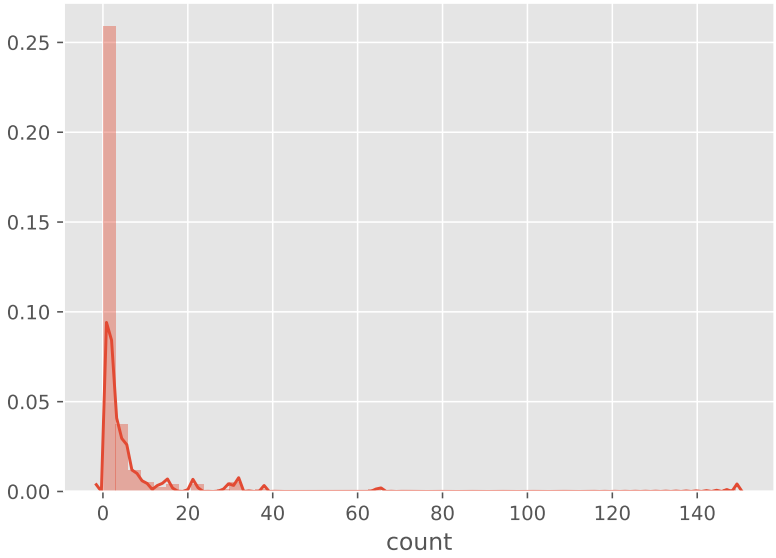

Превращаем переменную camper в категориальную.

```
df_fish['camper']=df_fish['camper'].astype('category')
```

Строим Пуассоновскую регрессию.

```
regr_pois = smf.glm('count ~ child + camper +  persons', data=df_fish,
                    family=sm.families.Poisson(link=sm.families.links.log)).fit()
```

Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'smf' is not defined

Detailed traceback:
  File "<string>", line 1, in <module>

```
regr_pois.summary()
```

Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'regr_pois' is not defined

Detailed traceback:
  File "<string>", line 1, in <module>

Посмотрим, равны ли среднее значение и дисперсия, как это предполагает рас-

пределение Пуассона.

```
(df_fish
 .filter(['count', 'camper'])
 .groupby('camper')
 .agg(['mean', 'var']))
```

```
        count
         mean         var
camper
0       1.524272    21.055778
1       4.537415   212.400988
```

И регрессию с остатками, имеющими отрицательное биномиальное распределение.

```
regr_bin = smf.glm('count ~ child + camper +  persons', data=df_fish,
           family=sm.families.NegativeBinomial(link=sm.families.links.log)).fit()
```

```
Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'smf' is not defined

Detailed traceback:
  File "<string>", line 1, in <module>
```

Проверим гипотезу о равенстве 0 коэффициента при переменной camper. Проведем тест Вальда.

```
hyp = '(camper = 0)'
regr_bin.wald_test(hyp)
```

```
Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'regr_bin' is not defined

Detailed traceback:
  File "<string>", line 1, in <module>
```

Посчитаем средний предельный эффект для каждой переменной.

```
pred = regr_pois.fittedvalues
```

```
Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'regr_pois' is not defined

Detailed traceback:
  File "<string>", line 1, in <module>
```

```
mean_mef_child = np.mean([regr_pois.params[1] * p for p in pred])
```

```
Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'pred' is not defined

Detailed traceback:
  File "<string>", line 1, in <module>
```

```
mean_mef_camper = np.mean([regr_pois.params[2] * p for p in pred])
```

Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'pred' is not defined

Detailed traceback:
File "<string>", line 1, in <module>

```
data_1 = pd.DataFrame({'child': df_fish['child'], 'camper': 1, 'persons': df_fish['persons']})
data_0 = pd.DataFrame({'child': df_fish['child'], 'camper': 0, 'persons': df_fish['persons']})
mean_mef_persons = np.mean([(regr_pois.predict(data_1)[i]-regr_pois.predict(data_0)[i])
                            for i in range(len(df_fish))])
```

Error in py_call_impl(callable, dots$args, dots$keywords): NameError: name 'regr_pois' is not defined

Detailed traceback:
File "<string>", line 2, in <module>
File "<string>", line 2, in <listcomp>

И модель с раздутыми нулями.

```
1
```

1

Проблемы:

2) предельные эффекты в Питоне
3) clogit ВООБЩЕ НЕ ПОЛУЧАЕТСЯ

Глава 5

Модели неупорядоченного выбора

Глава 6

Интструменты для простой регрессии

Глава 7

ARMA

Глава 8

Панельные данные

Глава 9

Гетероскедастичность в простой регрессии

Глава 10

PCA

Глава 11

Динамические панели

Глава 12

TOBIT, HECKIT

Глава 13

Treatment effect

Глава 14

Что-то там про совместимость и языки

Глава 15

Словарь